

Analýza hlavných komponentov (PCA)

Softvér na analýzu údajov — Projektová správa

Artem Vara

2026-04-29

Obsah

1	Úvod	1
2	Teoretické pozadie	2
2.1	Kovariančná matica	2
2.2	Vlastné čísla a vlastné vektory	2
2.3	Hlavné komponenty	3
2.4	Algoritmus PCA — krok za krokom	3
3	Dáta	3
3.1	Popis datasetu	3
3.2	Korelácie medzi premennými	4
4	Výpočet PCA	5
4.1	Ručný výpočet cez kovariančnú maticu	5
4.2	PCA pomocou funkcie prcomp()	6
4.3	Záťaž (Loadings)	7
5	Výsledky a vizualizácia	7
5.1	Scree plot — vysvetlená variabilita	7
5.2	Biplót — projekcia do 2D priestoru	8
5.3	Interpretácia komponentov	10
6	Záver	11
	Literatúra	12

1 Úvod

Moderná analýza dát sa čoraz častejšie stretáva s problémom **vysokej dimenzionality** — datasety môžu obsahovať desiatky až stovky premenných. Priama vizualizácia a interpretácia

takýchto dát je prakticky nemožná. Jednou z najelegantnejších matematických metód na riešenie tohto problému je **Analýza hlavných komponentov** (PCA, z angl. *Principal Component Analysis*).

PCA je technika zo štatistiky a lineárnej algebry, ktorá transformuje pôvodné premenné na nové — navzájom nekorelované — premenné nazývané **hlavné komponenty**. Tieto komponenty sú usporiadané tak, aby prvý komponent vysvetľoval čo najväčší podiel celkovej variability dát, druhý komponent vysvetľoval čo najväčší podiel zo zvyšnej variability, atď.

Metóda nachádza uplatnenie v mnohých oblastiach:

- **Biológia:** klasifikácia druhov podľa morfológických znakov (Jolliffe a Cadima 2016)
- **Ekonomika:** redukcia makroekonomických indikátorov
- **Počítačové videnie:** rozpoznávanie tvárí (Eigenfaces)
- **Chémia:** spektroskopická analýza

V tomto projekte aplikujeme PCA na klasický dataset `mtcars`, ktorý obsahuje technické parametre 32 automobilov z roku 1974. Cieľom je ukázať, ako je možné 10-rozmerný priestor premenných zredukovať na 2–3 dimenzie bez výraznej straty informácie.

Správa je členená nasledovne: v Sekcia 2 zhrnieme matematické pozadie metódy, Sekcia 3 popisuje použitý dataset, v Sekcia 4 vykonáme samotný výpočet PCA a v Sekcia 5 prezentujeme výsledky s vizualizáciami. Závěry sú zhrnuté v Sekcia 6.

2 Teoretické pozadie

2.1 Kovariančná matica

Nech $\mathbf{X}$ je dátová matica rozmeru $n \times p$, kde n je počet pozorovaní a p je počet premenných. Po **štandardizácii** (odčítaním priemeru a delením smerodajnou odchýlkou) dostaneme maticu $\mathbf{Z}$.

Kovariančná (resp. korelačná) matica je definovaná ako:

$$\mathbf{C} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z} \quad (1)$$

Matica $\mathbf{C}$ je symetrická a pozitívne semidefinitná rozmeru $p \times p$.

2.2 Vlastné čísla a vlastné vektory

Jadrom PCA je **spektrálny rozklad** kovariančnej matice definovanej v Rovnica 1:

$$\mathbf{C} \mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad i = 1, \dots, p \quad (2)$$

kde λ_i sú **vlastné čísla** (eigenvalues) a $\mathbf{v}_i$ sú zodpovedajúce **vlastné vektory** (eigenvectors). Vlastné vektory sú navzájom ortogonálne:

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

2.3 Hlavné komponenty

Hlavné komponenty sú lineárne kombinácie pôvodných premenných:

$$\mathbf{PC}_k = \mathbf{Z}\mathbf{v}_k$$

Podiel variability vysvetlenej k -tým komponentom:

$$\text{PVE}_k = \frac{\lambda_k}{\sum_{i=1}^p \lambda_i} \quad (3)$$

Vlastné vektory $\mathbf{v}_k$ sa nazývajú **loadings** (záťaž) a udávajú, ako silno každá pôvodná premenná prispieva k danému komponentu.

2.4 Algoritmus PCA — krok za krokom

1. Štandardizácia dát: $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$
2. Výpočet kovariančnej matice (Rovnica 1): $\mathbf{C} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z}$
3. Spektrálny rozklad (Rovnica 2): $\mathbf{C} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top$
4. Zoradenie vlastných čísel: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$
5. Projekcia dát: $\mathbf{PC} = \mathbf{ZV}$

3 Dáta

3.1 Popis datasetu

Použijeme vstavaný R dataset `mtcars` (R Core Team 2024), ktorý obsahuje informácie o 32 modeloch automobilov z roku 1974. Prvých šesť riadkov datasetu zobrazuje Tabuľka 1.

```
head(mtcars) |>
  kable(digits = 2) |>
  kable_styling(bootstrap_options = c("striped", "hover"), font_size = 12)
```

Tabuľka 1: Prvých 6 riadkov datasetu mtcars

	mpg	cyl	displacement	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160	110	3.90	2.62	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160	110	3.90	2.88	17.02	0	1	4	4
Datsun 710	22.8	4	108	93	3.85	2.32	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258	110	3.08	3.21	19.44	1	0	3	1

Hornet Sportabout	18.7	8	360	175	3.15	3.44	17.02	0	0	3	2
Valiant	18.1	6	225	105	2.76	3.46	20.22	1	0	3	1

Dataset obsahuje 32 pozorovaní a 11 premenných:

Premenná	Popis
mpg	Spotreba paliva (míle na galón)
cyl	Počet valcov
disp	Objem motora (cu.in.)
hp	Výkon (konské sily)
drat	Prevodový pomer zadnej nápravy
wt	Hmotnosť (1000 lbs)
qsec	Čas na 1/4 míle
vs	Typ motora (V alebo priamy)
am	Prevodovka (0 = automatická, 1 = manuálna)
gear	Počet prevodových stupňov
carb	Počet karburátorov


3.2 Korelácie medzi premennými

Pred PCA je užitočné preskúmať korelácie — výsledná korelačná matica je znázornená na Obrázok 1.

```
# Výpočet korelačnej matice
cor_mat <- cor(mtcars)

# Vizualizácia
cor_df <- as.data.frame(as.table(cor_mat))
names(cor_df) <- c("Var1", "Var2", "Correlation")

ggplot(cor_df, aes(Var1, Var2, fill = Correlation)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(Correlation, 2)), size = 3) +
  scale_fill_gradient2(low = "#d73027", mid = "white", high = "#1a9850",
    midpoint = 0, limits = c(-1, 1)) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  labs(x = NULL, y = NULL, fill = "Korelácia")
```



Obrázok 1: Korelačná matica premenných datasetu mtcars

Z korelačnej matice na Obrázok 1 vidíme silné korelácie medzi premennými (napr. `disp`, `cyl`, `hp`, `wt`), čo naznačuje, že PCA dokáže tieto premenné efektívne zlúčiť.

4 Výpočet PCA

4.1 Ručný výpočet cez kovariančnú maticu

Najskôr ukážeme PCA “od základov” — priamo cez spektrálny rozklad podľa postupu zo Sekcia 2.4:

```
# Štandardizácia
Z <- scale(mtcars)

# Kovariančná matica
C <- cov(Z)

# Spektrálny rozklad
```

```
eig <- eigen(C)

# Vlastné čísla
lambda <- eig$values
cat("Vlastné čísla (prvých 5):\n")
```

Vlastné čísla (prvých 5):

```
round(lambda[1:5], 4)
```

```
[1] 6.6084 2.6505 0.6272 0.2696 0.2235
```

```
# Vlastné vektory (loadings)
V <- eig$vectors
cat("\nPrvé dva vlastné vektory (PC1 a PC2):\n")
```

Prvé dva vlastné vektory (PC1 a PC2):

```
round(V[, 1:2], 3)
```

```
      [,1] [,2]
[1,]  0.363 -0.016
[2,] -0.374 -0.044
[3,] -0.368  0.049
[4,] -0.330 -0.249
[5,]  0.294 -0.275
[6,] -0.346  0.143
[7,]  0.200  0.463
[8,]  0.307  0.232
[9,]  0.235 -0.429
[10,] 0.207 -0.462
[11,] -0.214 -0.414
```

4.2 PCA pomocou funkcie prcomp()

```
# PCA pomocou vstavanej funkcie
pca <- prcomp(mtcars, center = TRUE, scale. = TRUE)

# Súhrn
summary(pca)
```

Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.5707	1.6280	0.79196	0.51923	0.47271	0.46000	0.3678
Proportion of Variance	0.6008	0.2409	0.05702	0.02451	0.02031	0.01924	0.0123
Cumulative Proportion	0.6008	0.8417	0.89873	0.92324	0.94356	0.96279	0.9751

	PC8	PC9	PC10	PC11
Standard deviation	0.35057	0.2776	0.22811	0.1485
Proportion of Variance	0.01117	0.0070	0.00473	0.0020
Cumulative Proportion	0.98626	0.9933	0.99800	1.0000

4.3 Zátáže (Loadings)

Zátáže prvých štyroch hlavných komponentov sú uvedené v Tabuľka 3.

```
loadings_df <- as.data.frame(pca$rotation[, 1:4])

loadings_df |>
  kable(digits = 3) |>
  kable_styling(bootstrap_options = c("striped", "hover")) |>
  column_spec(2, bold = TRUE, color = ifelse(abs(loadings_df$PC1) > 0.3, "#8B0000", "#008B00"))
```

Tabuľka 3: Zátáže prvých štyroch hlavných komponentov

	PC1	PC2	PC3	PC4
mpg	-0.363	0.016	-0.226	-0.023
cyl	0.374	0.044	-0.175	-0.003
disp	0.368	-0.049	-0.061	0.257
hp	0.330	0.249	0.140	-0.068
drat	-0.294	0.275	0.161	0.855
wt	0.346	-0.143	0.342	0.246
qsec	-0.200	-0.463	0.403	0.068
vs	-0.307	-0.232	0.429	-0.215
am	-0.235	0.429	-0.206	-0.030
gear	-0.207	0.462	0.290	-0.265
carb	0.214	0.414	0.529	-0.127

5 Výsledky a vizualizácia

5.1 Scree plot — vysvetlená variabilita

Podiel variability vysvetlenej jednotlivými komponentmi (PVE, Rovnica 3) znázorňuje scree plot na Obrázok 2.

```
# Výpočet PVE
pve <- lambda / sum(lambda) * 100
cumulative_pve <- cumsum(pve)


scree_df <- data.frame(
  PC = paste0("PC", 1:length(pve)),
```

```

PVE = pve,
Cumulative = cumulative_pve
)

ggplot(screedf[1:10, ], aes(x = reorder(PC, -PVE))) +
  geom_col(aes(y = PVE), fill = "#2166ac", alpha = 0.8) +
  geom_line(aes(y = Cumulative, group = 1), color = "#d73027", size = 1.2) +
  geom_point(aes(y = Cumulative), color = "#d73027", size = 3) +
  geom_hline(yintercept = 80, linetype = "dashed", color = "gray50") +
  annotate("text", x = 9, y = 82, label = "80% hranica", color = "gray40", size = 3.5) +
  scale_y_continuous(sec.axis = sec_axis(~., name = "Kumulatívne PVE (%)")) +
  labs(x = "Hlavný komponent", y = "Vysvetlená variabilita (%)") +
  theme_minimal(base_size = 12)

```



Obrázok 2: Scree plot: podiel vysvetlenej variability jednotlivými komponentmi

Ako vidno na Obrázok 2, prvé dva komponenty vysvetľujú **84.2%** celkovej variability, prvé tri komponenty **89.9%**.

5.2 Biplot — projekcia do 2D priestoru


Projekciu pozorovaní do roviny prvých dvoch komponentov spolu s vektormi záťaží zobrazuje Obrázok 3.


```

# Pridáme typ prevodovky ako faktor
mtcars_labeled <- mtcars |>
  mutate(
    transmission = factor(am, labels = c("Automatická", "Manuálna")),
    car_name = rownames(mtcars)
  )

autoplot(pca, data = mtcars_labeled,
  colour = "transmission",
  loadings = TRUE,
  loadings.label = TRUE,
  loadings.label.size = 3.5,
  loadings.colour = "darkred",
  loadings.label.colour = "darkred") +
  scale_color_manual(values = c("#2166ac", "#d6604d")) +
  labs(color = "Prevodovka", title = "PCA biplót - dataset mtcars") +
  theme_minimal(base_size = 12) +
  theme(legend.position = "bottom")

```



Obrázok 3: Biplot PCA: projekcia automobilov do roviny PC1–PC2 s vektormi záťaží


5.3 Interpretácia komponentov

Záťaž premenných na prvých dvoch komponentoch (porovnaj s Tabuľka 3) sú vizualizované na Obrázok 4.

```
loadings_long <- as.data.frame(pca$rotation[, 1:2]) |>
  mutate(variable = rownames(pca$rotation)) |>
  pivot_longer(cols = c(PC1, PC2), names_to = "PC", values_to = "loading")

ggplot(loadings_long, aes(x = reorder(variable, abs(loading)), y = loading, fill = loadi
  geom_col() +
  facet_wrap(~PC) +
```

```
coord_flip() +
scale_fill_manual(values = c("#d73027", "#1a9850"), labels = c("Záporná", "Kladná")) +
labs(x = NULL, y = "Záťaž", fill = "Smer") +
theme_minimal(base_size = 12)
```



Obrázok 4: Záťaž premenných na prvých dvoch komponentoch

PC1 (vysvetľuje 60.1% variability) je silne spojený s výkonom a veľkosťou motora (**hp**, **disp**, **cyl**, **wt**) — môžeme ho interpretovať ako **“silu vozidla”**. Premenné **mpg** a **drat** majú záporné záťaž (Obrázok 4), čo znamená, že silnejšie autá majú vyššiu spotrebu.

PC2 (vysvetľuje 24.1% variability) je primárne spojený s **qsec** a **vs** — súvisí s **typom a konfiguráciou motora**.

6 Záver

V tejto správe sme aplikovali Analýzu hlavných komponentov na dataset **mtcars** s nasledujúcimi závermi:

1. **Redukcia dimenzionality:** Z pôvodných 11 premenných stačia **2 komponenty** na vysvetlenie 84.2% variability, 3 komponenty pokrývajú 89.9% (pozri scree plot na Obrázok 2).
2. **Interpretácia:** PC1 reprezentuje “výkonnosť vozidla” (silne korelovaný s výkonom, objemom, hmotnosťou), PC2 reprezentuje “konfiguráciu motora” (Obrázok 4).
3. **Vizualizácia:** Biplot na Obrázok 3 jasne ukazuje separáciu manuálnych a automatických prevodoviek v priestore PC1–PC2, čo naznačuje, že typ prevodovky súvisí s celkovou výkonnosťou vozidla.
4. **Matematické základy:** PCA je elegantná aplikácia lineárnej algebry — spektrálny rozklad kovariančnej matice (Rovnica 2, Sekcia 2) poskytuje optimálnu lineárnu projekciu v zmysle maximalizácie rozptylu (Jolliffe a Cadima 2016).

PCA zostáva jednou z najpoužívanějších metód exploratívnej analýzy dát vďaka svojej matematickej jednoduchosti a širokej aplikovateľnosti (R Core Team 2024).

Literatúra

- Jolliffe, Ian T., a Jorge Cadima. 2016. *Principal Component Analysis*. 2nd vyd. New York: Springer. <https://doi.org/10.1007/b98835>.
- R Core Team. 2024. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. <https://www.R-project.org/>.